卒業論文

知識蒸留を用いたトマト葉病害判別モデルの改良

102210276　　梁媛源

名古屋大学

情報学部自然情報学科

複雑システム系

2026 年 2 月

目次

第 1 章　序論　1

第 2 章　トマト　3

2.1　トマト栽培の流れ 3

2.1.1　圃場準備 3

2.1.2　播種・育苗 3

2.1.3　定植 4

2.1.4　栽培管理 4

光・温度管理 4

灌水管理 4

施肥管理 4

2.1.5　収穫 4

2.2　病害防除 4

2.2.1　斑点細菌病（Bacterial Spot）. 5

2.2.2　早期病害（Early Blight）. 6

2.2.3　疫病（Late Blight）. 7

2.2.4　トマト葉カビ病（Leaf Mold）. 8

2.2.5　褐斑病（Septoria Leaf Spot）. 9

2.2.6　ハダニ類（Spider Mites）. 10

2.2.7　ターゲットスポット病（Target Spot）. 11

2.2.8　トマトモザイク病（Tomato Mosaic Virus）. 12

2.2.9　トマト黄化葉巻病（Tomato Yellow Leaf Curl Virus）. 13

2.2.10　健全葉（Healthy）. 14

第 3 章　理論　15

3.1　RGB 頻度分布 15

3.1.1　正規化 15

3.2　勾配ブースティング決定木と XGBoost 16

3.2.1　決定木の基本構造 16

3.2.2　勾配ブースティング決定木 16

3.2.3　勾配降下法に基づく学習過程 17

3.2.4　XGBoost における目的関数と正則化 18

XGBoost の基本的な考え方 18

目的関数の構成 18

決定木のモデル表現 18

正則化項 18
XGBoost におけるサンプル重みの役割 19
本研究における XGBoost の位置付け 19
3.3 知識蒸留（Knowledge Distillation）. 19
3.3.1 知識蒸留の基本的考え方 19
3.3.2 教師モデルと確率分布出力 19
3.3.3 ニューラルネットワークにおける標準的知識蒸留 20
温度スケーリングによる分布の平坦化 20
損失関数の構成 20
3.3.4 決定木モデルへの適用における課題 20

第 4 章 提案手法 22
4.1 概要 22
4.2 使用データ 22
4.2.1 クラスとラベルの定義 23
4.2.2 データセットの特徴 23
4.2.3 データ前処理の全体像 23
4.2.4 背景透過処理 23
4.2.5 アルファマスクを用いた RGB 頻度分布の算出 24
4.2.6 特徴量ベクトルの構成 24
4.2.7 対数変換 24
4.2.8 データの利用方法 24
4.2.9 データの利用条件 24
4.2.10 データセット提供者への謝辞 25
4.2.11 データの分割方法 25
4.3 問題設定と入出力定義 25
4.3.1 入力特徴量 25
4.3.2 出力クラス 25
4.4 提案手法の設計方針 25
4.5 知識蒸留に基づく学習手法 26
4.5.1 教師確率分布の取得 26
4.5.2 温度スケーリング 26
4.5.3 サンプル展開と重み付け（top-m）. 26
4.5.4 Hard / Soft 混合学習 27
4.5.5 提案手法のアルゴリズム 27
4.6 ハイパーパラメータ 28
4.6.1 教師モデル（Teacher）. 28
4.6.2 生徒モデル（Student-Base / Student-KD）. 28
4.6.3 知識蒸留パラメータ 28
4.7 実験プロトコル 28
4.7.1 再現性の確保 28
4.7.2 ベースラインとの比較方法 29
4.8 評価指標 29
4.8.1 正答率（Accuracy）. 29

4.8.2 Macro-F1 スコア 29
4.8.3 病害再現率（二値化 Recall） 30
4.8.4 推論時間 30
4.8.5 Student-Base と Student-KD の改善量（差分指標） 30

第 5 章 実験 31
5.1 実験概要 31
5.2 実験条件 31
5.2.1 使用データ 31
5.2.2 データ分割方法 31
5.2.3 モデル構成 32
5.2.4 実験環境 32
5.2.5 ハイパーパラメータ設定 32
5.3 ベースラインの確認 32
5.4 知識蒸留パラメータの網羅的評価 33
5.4.1 全パラメータ組合せの結果 33
5.4.2 混合係数 α の影響 34
5.4.3 展開クラス数 m の影響 34
5.5 最良条件における 3 モデルの比較 35
5.5.1 分類性能の比較 35
5.5.2 推論時間の比較 35
5.5.3 推論時間短縮の考察 36
5.6 考察 36
5.6.1 本研究の実験結果のまとめ 36
5.6.2 分類性能の改善が限定的である理由 36
5.6.3 推論時間短縮の意義 37
5.6.4 本研究の限界と今後の展望 37

第 6 章 結論 38

第 7 章 謝辞 40

図目次

2.1 斑点細菌病にかかったトマト葉の外観例 [3] 5
2.2 早期病害にかかったトマト葉の外観例 [3] 6
2.3 疫病にかかったトマト葉の外観例 [3] 7
2.4 トマト葉カビ病にかかったトマト葉の外観例 [3] 8
2.5 褐斑病にかかったトマト葉の外観例 [3] 9
2.6 ハダニ類にかかったトマト葉の外観例 [3] 10
2.7 ターゲットスポット病にかかったトマト葉の外観例 [3] 11
2.8 トマトモザイク病にかかったトマト葉の外観例 [3] 12
2.9 トマト黄化葉巻病にかかったトマト葉の外観例 [3] 13
2.10 健全なトマト葉の外観例 [3] 14

3.1 RGB 頻度分布特徴量の作成手順 16
3.2 勾配ブースティング決定木における加法モデル構造 17
3.3 本研究における知識蒸留の概念図（top-m 展開とサンプル重み）. 21

表目次

4.1 クラスとラベルの対応 23

5.1 教師モデル（Teacher）のハイパーパラメータ 32
5.2 生徒モデル（Student-Base / Student-KD）のハイパーパラメータ 33
5.3 知識蒸留に関するパラメータ設定 33
5.4 Teacher と Student-Base の性能比較（5 seed 平均） 33
5.5 Student-KD の Student-Base に対する性能差分（Δ，5 seed 平均，Macro-F1 降順） 34
5.6 3 モデルの分類性能比較（最良条件：$\alpha = 0.03$，$m = 2$，5 seed 平均） 35
5.7 3 モデルの計算時間比較（最良条件：$\alpha = 0.03$，$m = 2$，5 seed 平均） 35
5.8 Student-Base と Student-KD の決定木構造比較（5 seed 平均） 36

第 1 章

序論

近年，日本の農業においては，農業従事者の高齢化および担い手不足が深刻な課題となっている．農林水産省の統計によれば，基幹的農業従事者数は長期的に減少傾向にあり，令和 5 年（2023 年）には約 116.4 万人と，平成 12 年（2000 年）の約 240 万人から 20 年以上で半減している．このうち，65 歳以上の高齢者が全体の約 7 割を占め，平均年齢は 68.7 歳に達しており，農業従事者の高齢化が急速に進行している．一方，49 歳以下の若年層農業従事者は約 13.3 万人と全体の 1 割程度にとどまっており，新規就農者数も令和 4 年（2022 年）には前年比 12.3% 減の 4 万 5,840 人となるなど，担い手不足は今後さらに深刻化すると予測されている [18].

このような背景から，農業分野においては作業の省力化，生産性の向上，および熟練者に依存しない栽培管理技術の確立が強く求められている．これに対する解決策として，ロボット技術や AI，IoT などの情報通信技術を活用したスマート農業が注目されている．スマート農業の導入により，農作業の効率化や作業者の身体的負担の軽減，さらには経営管理の合理化を通じた農業全体の生産性向上が期待されている [16].

農作物の安定生産において特に重要なのが，病害の早期発見および適切な対処である．トマトは日本国内外で広く栽培されている主要作物の一つであり，その葉に発生する病害は収量および品質の低下に直結する．トマト葉には，褐斑病や斑点細菌病などの真菌・細菌性病害，トマト黄化葉巻病やモザイク病などのウイルス性病害，さらにハダニ類など害虫被害による症状まで多様な病害が存在する．これらの病害は周囲の葉や株へ伝染する可能性が高く，被害拡大を防ぐためには早期発見・早期対処が不可欠である [19].

従来，病害診断は熟練農業従事者による目視観察に依存してきたが，新規就農者や経験の浅い作業者にとっては高い専門知識が必要であり，正確な診断は容易ではない．そこで，画像処理および機械学習を用いて病害を自動的に判別する研究が数多く行われている [15]．先行研究として，矢賀による「RGB 頻度分布によるトマト葉病害診断の改良」が挙げられる [13]．矢賀の研究では，トマト葉画像から RGB 頻度分布を抽出し，XGBoost を用いた分類モデルによりトマト葉病害の 10 クラス分類を実現している．

本研究では，矢賀の研究を基盤とし，Kaggle において公開されている「Tomato leaf disease detection using CNN」のデータセットを用いて，トマトの葉画像から RGB 頻度分布を取得し，それらを入力特徴量として XGBoost 分類モデルを構築する．さらに，高容量な教師モデル（Teacher）が出力するクラス確率分布を学習信号として，低容量な生徒モデル（Student）へ知識を転移する Teacher–Student 型の知識蒸留枠組みを導入し，判別性能と推論時間の観点から本手法の適用可能性について検討する．

一方で，農業現場における実運用を考慮すると，モデルの分類精度のみならず，推論時間や計算コストといった実装上の制約も重要な要素となる．一般に，モデル精度を向上させるためには，学習回数やモデル規模を増加させる必要があり，その結果として計算量や推論コストが増大する傾向がある．このような大規模モデルは，計算資源が限られた農業現場の機器への導入が困難であり，実用性の観点から課題が残る．そのため，分類性能と計算効率を両立したモデル構成が求められている．

知識蒸留は，高性能なモデルが獲得した判断情報をより小規模なモデルへ転移するための学習手法であ

り，ニューラルネットワークを対象として広く研究されてきた. しかし，XGBoost をはじめとする決定木ベースのモデルに対する知識蒸留の適用事例は限られており，その有効性や適用条件についてはいまだ十分に検討されていない. そこで本研究では，XGBoost 同士の Teacher–Student 構成において，教師モデルの出力確率分布をサンプル重みとして生徒モデルの学習に反映させる蒸留手法を提案し，蒸留強度を制御するパラメータを変化させながら，分類精度，F1 値，再現率に加え，推論時間の観点から基礎的な検討を行う.

本論文は全 6 章から構成される．本章では研究の背景および目的について述べる．第 2 章ではトマト栽培およびトマト病害の概要について述べる．第 3 章では，本研究で用いる関連技術として，RGB 頻度分布，XGBoost および知識蒸留について説明する．第 4 章では提案手法の詳細を示し，第 5 章において数値実験および結果に対する考察を行う．最後に第 6 章で結論を述べる.

第 2 章

トマト

2.1　トマト栽培の流れ

トマト栽培は，圃場準備，播種・育苗，定植，栽培管理，収穫の各工程から構成される体系的な生産プロセスである．施設栽培においては，春期および秋期は被覆資材による保温管理を行い，夏期にはハウス側面や裾部を開放することで，高温や降雨の影響を軽減し，栽培期間の拡大と安定生産を実現している．このような作型管理によって，高品質かつ安定したトマト生産が可能となる [17].

2.1.1　圃場準備

トマトは排水性および通気性が良好で肥沃な土壌を好む作物である．圃場準備では，耕起・整地を行い，残渣・雑草の除去や病害虫発生源の低減に努めることが重要である．また，連作を避けることが望ましく，同じナス科作物を連続して栽培する場合には土壌消毒や台木利用などの対策が必要とされる．

有機栽培等では，完熟堆肥や有機物資材を適正量施用することで，通気性・排水性・保水性を改善し土壌物理性・化学性を向上させる．ただし，堆肥等の過剰施用は養分過剰や生理障害につながる可能性があるため，事前の土壌診断を基に施用量を設計することが望ましい．

一般的な施肥設計の一例として，10a 当たり窒素 10～15kg，相当量のリン酸およびカリを均衡に施用し，土壌 pH を 6.0～6.5，EC 値を適正範囲内に維持することが推奨される [17].

2.1.2　播種・育苗

育苗工程はトマト栽培において生育初期の基礎を形成し，最終的な収量および果実品質に影響を与える重要なプロセスである．播種は清潔なセルトレイまたは播種床に行い，覆土後は十分にかん水し発芽温度（20～30 ℃ 程度）を確保する．

育苗期の環境管理においては，発芽後に光照を十分に与え，徒長を抑制するとともに，夜間 10～15 ℃，日中 25～30 ℃ 程度の温度帯を維持することが望ましい．

育苗後期には本葉 1～2 枚で鉢上げし，根の損傷を避けつつ健全な根圏を確保する．さらに，育苗期間中の灌水は，乾燥によるストレスを回避するため，早朝～午前中を中心に適切に行うことが重要である．

液肥による追肥は肥料成分の不足を補い，苗体の健全な生育を促進するが，施肥量および頻度は生育状態に応じて適宜調整する必要がある [17].

2.1.3　定植

播種後約 50～55 日目，または第 1 花房の第 1 花が開花し始めた時期を定植適期とする．定植前には植穴およびポット苗の土壌を十分に灌水し，定植時には土壌と苗の根系が良好に接触するように準備する．

定植は浅植えとし，定植直後は土壌との密着を良好にするため適度に灌水を行う．その後，果実肥大期に至るまで水分不足が生じないよう，こまめな灌水管理を行うことが望ましい．

植え穴が小さい場合には白絹病や菌核病が発生しやすくなるため，十分な大きさを確保することが重要である．光合成効率を最大化し，生育を安定させるために，適切な栽植密度を維持することも重要である [17].

2.1.4　栽培管理

光・温度管理

トマトは日射量の多い環境で良好に生育し，日照不足は徒長，着果・果実肥大の低下につながる可能性がある．生育適温は日中 23～28 ℃，夜間 10～15 ℃ 程度であり，30 ℃ を超える高温条件および急激な温度変化は生育不良の要因となる可能性がある [17].

灌水管理

トマトは過湿に弱い性質を有するため，生育段階に応じた適切な水分管理が必要である．定植後は活着促進のため十分な灌水を行い，その後は根群の発達を促すため灌水量を生育段階に合わせて調整する [17].

施肥管理

基肥のみでは生育中期以降に養分が不足する場合があるため，生育状況に応じて追肥を行う必要がある．基肥として堆肥や有機肥料を施用し，追肥は成分および生育ステージに応じて適宜供給することが推奨されている [17].

2.1.5　収穫

トマトの収穫時期は品種，栽培環境および用途によって異なるが，一般に果実の着色が進み，品質が安定した段階で収穫を行うことが望ましい．完熟に近い状態で収穫された果実は糖度および風味が高く，生食用トマトとしての品質向上につながる．

収穫作業は果実への機械的損傷を避けるため，果柄部を清潔なハサミ等で切除して行う．収穫後の果実は直射日光や高温を避け，速やかに選別・調整・搬送することが重要である．また，収穫適期を過ぎた果実を圃場内に残すと，病害虫の発生源となる可能性があるため，定期的かつ計画的な収穫管理が安定生産の基礎となる．

以上のように，適切な収穫管理は果実品質の維持と市場価値の向上に直結し，トマト生産全体の収益性を左右する重要な工程である [17].

2.2　病害防除

トマト葉病害は光合成機能を阻害し，収量および品質低下を引き起こす主要因である．本研究では，以下の 9 種類の病害および健全葉の計 10 クラスを対象とする．

- 斑点細菌病（Bacterial Spot）
- 早期病害（Early Blight）
- 疫病（Late Blight）

- トマト葉カビ病（Leaf Mold）
- 褐斑病（Septoria Leaf Spot）
- ハダニ類（Spider Mites）
- ターゲットスポット病（Target Spot）
- トマトモザイク病（Tomato Mosaic Virus）
- トマト黄化葉巻病（Tomato Yellow Leaf Curl Virus）
- 健全葉（Healthy）

以下では，各病害について外観的特徴，病因，予防および対策の観点から整理する [19].

2.2.1 斑点細菌病（Bacterial Spot）

(a) 症状例 1　　(b) 症状例 2

図 2.1: 斑点細菌病にかかったトマト葉の外観例 [3]

病症

葉や茎に水が染みたような小斑点が現れ，進行すると葉脈に沿って拡大し褐色の病斑を形成する．重症化すると葉の光合成能力が低下し，生育不良を引き起こす [9].

病因

病原は細菌であり，土壌や病葉中で越冬する．泥はねにより葉面へ付着し，傷口や気孔から侵入して増殖する．高温多湿条件で発病が助長される [9].

予防および対策

排水管理と換気の徹底により過湿を避ける．発病葉は速やかに除去し，作業器具の消毒など衛生管理を行う [9].

2.2.2　早期病害（Early Blight）

(a) 症状例 1　　(b) 症状例 2

図 2.2: 早期病害にかかったトマト葉の外観例 [3]

病症

葉に小さな褐色斑点が発生し，拡大すると同心円状の病斑を形成する．進行すると葉の黄変や落葉が生じ，果実や茎にも病斑が現れる．

病因

糸状菌による病害であり，胞子は土壌中で生存する．高温多湿および葉の長時間濡れにより発病しやすく，雨風や農機具を介して感染が拡大する．

予防および対策

耐病性品種の利用，薬剤防除，感染葉の早期除去を行い，圃場の衛生管理を徹底する．

2.2.3　疫病（Late Blight）

(a) 症状例 1　　(b) 症状例 2

図 2.3: 疫病にかかったトマト葉の外観例 [3]

病症

初期には葉に水が染みたような暗緑色の不定形斑が現れる．病斑は急速に拡大し，葉全体がしおれて枯死することがある．湿度が高い条件では病勢が強く，葉裏側や病斑周縁にかび状の発生が観察される場合がある．乾燥条件では病斑部が褐変して乾いた外観となり，葉の一部が欠けたように枯れ込む [9].

病因

病原は糸状菌に類する病原体であり，土壌中や被害残渣に由来する．降雨や灌水による泥はねで病原体が葉面へ付着し，気孔などから侵入して発病する．長雨が続く時期や排水不良の圃場では発生が助長され，急速にまん延するリスクが高い [9].

予防および対策

排水性の確保と圃場の過湿回避を基本とする．マルチング等で泥はねを抑え，葉面が長時間濡れた状態にならないよう換気・通風を確保する．発病部位が確認された場合は早期に除去し，被害残渣を圃場に残さない．必要に応じて薬剤防除を組み合わせる [9].

2.2.4　トマト葉カビ病（Leaf Mold）

(a) 症状例 1

(b) 症状例 2

図 2.4: トマト葉カビ病にかかったトマト葉の外観例 [3]

病症

葉の表面に淡黄色～黄緑色の小斑点が生じ，輪郭が不明瞭なまま拡大する．進行すると葉裏面に灰褐色のかび（胞子形成）が発生し，葉が黄変して枯れ込む．施設内で発生すると，葉の下位から上位へ広がりやすく，収量や品質に影響を及ぼす [14].

病因

病原は糸状菌であり，施設内への侵入経路としては，種子表面由来，資材・衣類等の持ち込み，および空気中からの侵入（風媒）などが考えられる．高湿度環境で発生しやすく，換気不足や過密条件で病勢が強まる [14].

予防および対策

施設内の湿度を上げない管理（換気，結露抑制）を徹底する．抵抗性品種の利用や種子消毒などにより侵入・初期感染を抑える．発病葉は早期に除去し，必要に応じて薬剤防除を行う．作業動線や資材の衛生管理により，施設内での伝搬を抑制する [14].

2.2.5　褐斑病（Septoria Leaf Spot）

(a) 症状例 1　　(b) 症状例 2

図 2.5: 褐斑病にかかったトマト葉の外観例 [3]

病症

葉に小さな褐色〜黒褐色の斑点が多数生じ，進行すると斑点が拡大・多発して葉全体の黄変や早期落葉が起こる．斑点は円形〜不整形で，周辺がややぼやけた外観となることがある．多湿条件では病斑上にかび状の付着物が見られる場合がある [9].

病因

病原は糸状菌であり，病葉や圃場残渣に由来して発生する．連作条件や過湿条件で発生しやすく，降雨や灌水による泥はねで伝搬する．病原体が圃場内に残存すると，次作への持ち越しが起こり得る [9].

予防および対策

被害葉や残渣を圃場から除去し，病原体の残存を抑える．連作回避や排水改善，泥はね防止を組み合わせて発生条件を弱める．発病が確認された場合は早期除去を行い，必要に応じて薬剤防除を実施する [9].

2.2.6 ハダニ類（Spider Mites）

(a) 症状例 1

(b) 症状例 2

図 2.6: ハダニ類にかかったトマト葉の外観例 [3]

病症

葉に白色〜淡黄色の微小な斑点状退色が現れ，進行すると葉全体がかすれたように退色する．被害が拡大すると光合成能力が低下し，葉の枯死や落葉が生じる．多発時には葉裏に個体が集まり，糸を張ってクモの巣状の外観を呈することがある．肉眼では確認しにくく，被害が進んでから気付く場合がある [9].

病因

原因はダニ類による吸汁であり，葉組織が局所的に破壊され退色が生じる．高温乾燥条件で増殖が促進され，短期間で個体数が増加する．施設栽培では外部からの侵入後に急増しにくい [9].

予防および対策

圃場・施設内の乾燥を避け，発生初期に密度を上げない管理を行う．被害葉の早期除去，水での洗い流し等の物理的手段を併用する．薬剤抵抗性が問題となる場合があるため，必要に応じて天敵利用など複数手段を組み合わせ，発生を抑える [9].

2.2.7　ターゲットスポット病（Target Spot）

(a) 症状例 1

(b) 症状例 2

図 2.7: ターゲットスポット病にかかったトマト葉の外観例 [3]

病症

葉に小さな褐色斑が現れ，拡大すると中心部が淡色で周辺が濃色となる同心円状の病斑を形成する．病斑が多発すると葉の黄変や枯死が進行し，生育が阻害される．葉だけでなく茎や果実にも病斑が生じる場合があり，品質低下につながる．

病因

病原体による感染であり，高温多湿条件で発生が助長される．葉が密集して通風が悪い環境では病勢が強まりやすい．水滴や作業を介して病原体が移動し，圃場内で拡大する可能性がある．

予防および対策

過密を避け，整枝や摘葉により通風・採光を確保する．病斑が確認された場合は早期に感染部位を除去し，圃場衛生を保つ．必要に応じて薬剤防除を組み合わせ，発生拡大を抑える．

2.2.8 トマトモザイク病（Tomato Mosaic Virus）

(a) 症状例 1

(b) 症状例 2

図 2.8: トマトモザイク病にかかったトマト葉の外観例 [3]

病症

葉に濃淡のあるモザイク状の斑が現れ，葉形のゆがみや生育抑制が起こる．症状は個体や生育段階により差があるが，発病株では樹勢が低下し，果実の品質・収量に影響が出ることがある．葉脈周辺の色調変化が目立つ場合もある [9].

病因

原因はウイルスであり，媒介昆虫による伝搬のほか，作業手・器具・資材などを介した接触伝染が問題となる．感染源が残存すると，作業の繰り返しにより圃場内で拡大する可能性がある [9].

予防および対策

発病株は治療が困難であるため，感染株の速やかな除去・処分により伝染源を断つ．器具消毒や手指の衛生管理を徹底し，作業による拡散を抑える．媒介昆虫対策を併用し，施設では防虫ネット等で侵入を低減する [9].

2.2.9 トマト黄化葉巻病（Tomato Yellow Leaf Curl Virus）

(a) 症状例 1

(b) 症状例 2

図 2.9: トマト黄化葉巻病にかかったトマト葉の外観例 [3]

病症

葉が黄化し，葉縁が内側または上方へ巻き上がる．新葉で症状が顕著となり，株全体の生育が抑制される．結果として着果不良や果実肥大不良が生じ，収量低下が大きい．症状が進行すると奇形葉が増え，樹勢の回復が難しくなる．

病因

原因はウイルスであり，主にタバココナジラミによって媒介される．媒介虫が施設内に侵入すると感染が急速に広がり得る．土壌・種子由来の伝染は主要因ではないとされる．

予防および対策

媒介虫の侵入防止を最優先とし，防虫ネットや施設出入口管理を徹底する．発病株を確認した場合は速やかに除去・処分し，感染拡大を抑える．栽培終了後の残さ処理を適切に行い，媒介虫の増殖源を残さない．必要に応じて抵抗性品種の利用を検討する．

2.2.10　健全葉（Healthy）

(a) 健全例 1　　(b) 健全例 2

図 2.10: 健全なトマト葉の外観例 [3]

健全葉は葉面が概ね均一な緑色を示し，斑点，退色，黄変，かび状付着，巻き上がり等の異常が認められない．病害クラスとの比較の基準として，本研究では健全葉を独立したクラスとして扱う．

第 3 章

理論

3.1 RGB 頻度分布

本研究では，トマト葉の外観的特徴を数値化するための画像特徴量として，RGB 頻度分布を用いる. RGB 頻度分布とは，画像中の各ピクセルが持つ色成分の値を集計し，色成分の出現傾向を分布として表したものである.

RGB はデジタル画像における基本的な色表現モデルであり，Red（R），Green（G），Blue（B）の三成分の組合せによって色が表現される. 一般的な 8 bit 画像では，各成分は 0 から 255 の 256 階調で表されるため，1 ピクセルは (R, G, B) の 3 つの値によって表される. また，RGB 空間全体では $256^3 \approx 1.67 \times 10^7$ 通りの色を表現することができる.

本研究では，各トマト葉画像について，全ピクセルの R，G，B 各成分の値を集計し，それぞれの頻度分布を画像の特徴量として用いる.

3.1.1 正規化

本研究では，背景が除去されたトマト葉画像を用いて RGB 頻度分布を作成している. このとき，画像ごとにピクセル数が異なるため，そのままでは RGB 頻度分布の値の大きさに違いが生じる. そこで，各画像の RGB 頻度分布について，それぞれの頻度値を画像内の総ピクセル数で割ることで正規化を行った.

この処理により，画像サイズの違いによる影響を抑え，すべての画像を同一基準で比較できるようにしている. 本研究では，この正規化後の RGB 頻度分布を機械学習モデルの入力特徴量として用いる.

図 3.1 に RGB 頻度分布特徴量の作成手順を示す．去背景済みのトマト葉画像から RGB 各チャンネルの画素値（0–255）を集計し，総画素数で正規化した頻度分布を特徴ベクトルとして得る．したがって，本研究のモデル入力は画像そのものではなく，統計的特徴量である.

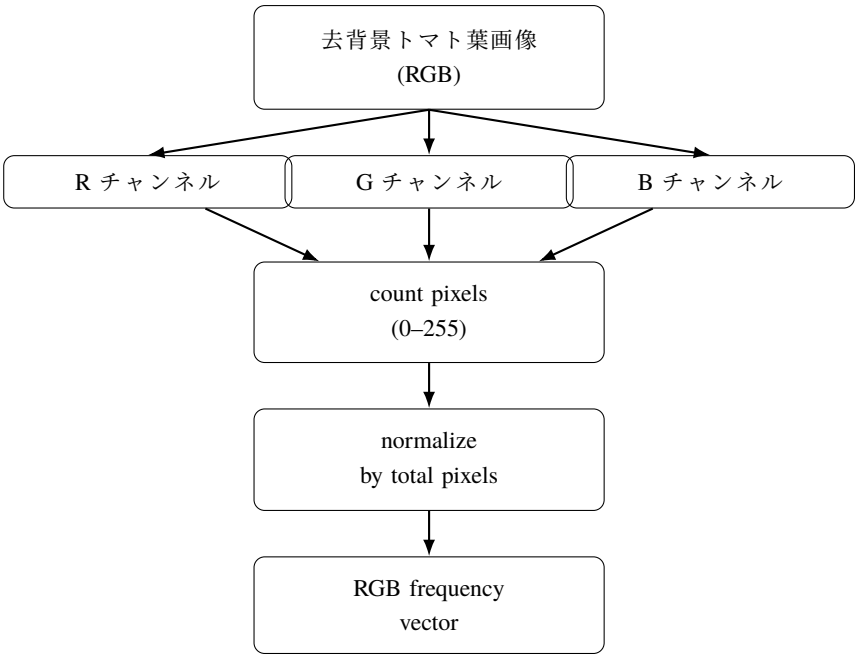

図 3.1: RGB 頻度分布特徴量の作成手順

3.2 勾配ブースティング決定木と XGBoost

3.2.1 決定木の基本構造

決定木（Decision Tree）は，特徴量空間を逐次的に分割することによって，入力データを分類または回帰する教師あり学習モデルである [1]．決定木は，データ全体を表すルートノードから始まり，各内部ノードにおいて特徴量と閾値に基づく分岐を行い，最終的に到達した葉ノードにおいて予測結果を出力する階層的構造を持つ．

分類問題においては，各葉ノードにはクラスラベル，あるいは各クラスに属する確率が割り当てられる．入力データ x が与えられたとき，決定木はルートノードから分岐条件を順に評価し，一つの葉ノードに到達することで予測値 $\hat{y}$ を決定する．

決定木は，

- モデル構造が直感的で理解しやすい
- 数値特徴量およびカテゴリ特徴量の両方を扱える

といった利点を持つ．一方で，単一の決定木は訓練データに強く適合しやすく，過学習を引き起こしやすいという課題がある．

この過学習の問題を軽減し，汎化性能を向上させるために，複数の決定木を組み合わせるアンサンブル学習が提案されてきた．その代表的な手法の一つが，勾配ブースティング決定木である．

3.2.2 勾配ブースティング決定木

勾配ブースティング決定木（Gradient Boosting Decision Tree; GBDT）は，複数の決定木を逐次的に学習し [4]，それらの出力を加算することで高精度な予測モデルを構築するアンサンブル学習手法である．各決定木は弱学習器として機能し，前段階までのモデルが生じた誤差を補正する役割を担う．

入力データ集合 $\{(x_i, y_i)\}_{i=1}^{N}$ に対し，GBDT による予測値 $\hat{y}_i$ は，複数の決定木の出力の和として次式で

表される：

$$\hat{y}_i = \sum_{t=1}^{T} f_t(x_i), \tag{3.1}$$

式 (3.1) は，図 (3.2) に示すように「決定木を逐次的に追加し，それらの出力を加算する」加法モデルとして理解できる．すなわち，第 1 段階の決定木 f_1 が作る予測誤差（残差）を手掛かりとして次段の決定木 f_2 を学習し，この過程を繰り返すことで，最終的に $\sum_{t=1}^{T} f_t(x)$ として予測を与える．

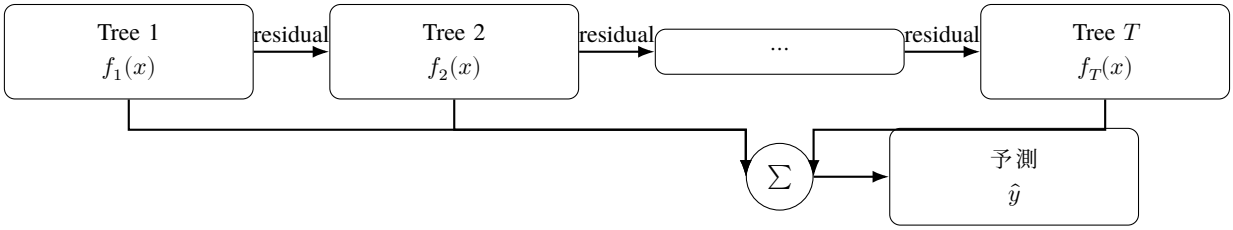

図 3.2: 勾配ブースティング決定木における加法モデル構造

ここで $f_t(x)$ は，第 t 段階で学習された決定木を表す．GBDT では，初期モデルを構築した後，各段階において，それまでの予測結果に基づく誤差を補正するように，新たな決定木を逐次的に追加していく．

この学習過程は，損失関数 $\ell(y_i, \hat{y}_i)$ を用いて定式化される．第 t 段階では，現在の予測値 $\hat{y}_i^{(t-1)}$ における損失の負の勾配

$$r_i^{(t)} = -\left.\frac{\partial \ell(y_i, \hat{y}_i)}{\partial \hat{y}_i}\right|_{\hat{y}_i = \hat{y}_i^{(t-1)}} \tag{3.2}$$

を教師信号として，決定木 f_t が学習される．

このように，GBDT は，各段階でモデルの誤差を段階的に補正することで予測性能を高める手法であり，単一の決定木では表現が困難な複雑な決定境界も，複数の決定木の加算によって近似可能となる．

3.2.3 勾配降下法に基づく学習過程

GBDT の学習過程は，損失関数を最小化するための逐次最適化問題として捉えることができる．この観点から，GBDT は経験的なアルゴリズムではなく，明確な最適化原理に基づく学習手法として位置付けられる．

訓練データ集合 $\{(x_i, y_i)\}_{i=1}^{N}$ が与えられたとき，予測モデル $F(x)$ の学習は，次式で定義される損失関数の最小化問題として表される：

$$\mathcal{L} = \sum_{i=1}^{N} \ell(y_i, F(x_i)), \tag{3.3}$$

ここで $\ell(\cdot)$ は，予測値 $F(x_i)$ と正解ラベル y_i との誤差を評価する損失関数である．GBDT では，モデル $F(x)$ を一度に最適化するのではなく，決定木を加算的に構成することで段階的に近似を行う．

第 $t-1$ 段階までに得られたモデルを $F_{t-1}(x)$ とすると，第 t 段階におけるモデル更新は，新たな決定木 $f_t(x)$ を加えることで，

$$F_t(x) = F_{t-1}(x) + f_t(x) \tag{3.4}$$

と表される．ここで，決定木 $f_t(x)$ は，現在のモデル $F_{t-1}(x)$ における損失関数の勾配情報を近似するように学習される．

具体的には，各訓練データ (x_i, y_i) に対して，予測値に関する損失の負の勾配

$$r_i^{(t)} = -\left.\frac{\partial \ell(y_i, F(x_i))}{\partial F(x_i)}\right|_{F(x)=F_{t-1}(x)} \tag{3.5}$$

を計算し，この値を目的変数として決定木を構築する．この $r_i^{(t)}$ は，現在のモデルが十分に表現できていない誤差成分を表しており，一般に残差と呼ばれる．

以上のように，GBDT における学習過程は，関数空間上での勾配降下法を，決定木という関数クラスを用いて近似的に実現したものと解釈できる．この枠組みにより，GBDT は回帰問題のみならず分類問題に対しても適用可能であり，高い汎化性能を示すことが知られている [2].

3.2.4 XGBoost における目的関数と正則化

XGBoost の基本的な考え方

XGBoost（eXtreme Gradient Boosting）は，勾配ブースティング決定木を基盤としつつ，学習の安定性と汎化性能を高めるために，目的関数へ明示的な正則化項を導入した手法である [2]．GBDT が逐次的に決定木を加算する枠組みを採るのに対し，XGBoost では各段階の学習を最適化問題として明確に定式化する点に特徴がある．

目的関数の構成

XGBoost における学習は，損失関数と正則化項からなる目的関数の最小化として定式化される．第 t 段階における目的関数は，次式で与えられる：

$$\mathcal{L}^{(t)} = \sum_{i=1}^{N} \ell(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t), \tag{3.6}$$

ここで，$\ell(\cdot)$ は予測値と正解ラベルの誤差を評価する損失関数，$f_t(x)$ は新たに追加される決定木を表す．本研究で用いている多クラス分類では，XGBoost の `multi:softprob` 目的関数が採用されており，各入力に対してクラス確率分布が出力される．

決定木のモデル表現

XGBoost において，決定木 $f(x)$ は，入力 x を葉ノードへ写像し，その葉に対応するスコアを出力する関数として表される．すなわち，

$$f(x) = w_{q(x)}, \tag{3.7}$$

ここで $q(x)$ は入力 x が到達する葉ノードのインデックス，w は各葉に割り当てられたスコアである．この表現により，決定木全体の複雑さを葉ノード数と葉の重みとして評価することが可能となる．

正則化項

XGBoost では，決定木の複雑さを抑制するため，次式で与えられる正則化項が導入されている：

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2, \tag{3.8}$$

ここで，T は決定木の葉ノード数，w_j は第 j 葉に対応する重みである．γ は木構造の複雑さに対する罰則，λ は葉ノード重みに対する L_2 正則化の強さを制御するパラメータである．

この正則化項により，不必要に複雑な木構造が抑制され，過学習を防ぎつつ安定した学習が可能となる．本研究においては，`max_depth` や `num_boost_round` を調整することで，モデル容量を制御している．

XGBoost におけるサンプル重みの役割

XGBoost では，訓練データの各サンプルに対して重み w_i（`sample_weight`）を設定することができる．この重みは，目的関数における損失項に乗算される形で作用し，重みの大きいサンプルほど分岐条件の決定に強く影響する．

具体的には，重み付きの目的関数は次式で表される：

$$\mathcal{L}^{(t)} = \sum_{i=1}^{N} w_i \cdot \ell(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t). \tag{3.9}$$

この機構により，特定のサンプルを重点的に学習させたり，データの信頼度に応じた学習を行うことが可能となる．本研究では，このサンプル重み機構を知識蒸留の実装に活用しており，その詳細は第 4 章にて述べる．

本研究における XGBoost の位置付け

本研究では，教師モデルおよび生徒モデルの双方に XGBoost を用いており，両者は同一の学習アルゴリズムに基づきつつ，学習反復回数やモデル容量を変化させることで構成されている．これにより，高容量な教師モデルが獲得した出力確率分布を，軽量な生徒モデルへと転移するための基盤として，XGBoost の確率出力およびサンプル重み機構を活用する．

以上のように，XGBoost は，本研究における分類性能と計算効率の両立を支える基盤的手法として重要な役割を果たしている．

3.3 知識蒸留（Knowledge Distillation）

3.3.1 知識蒸留の基本的考え方

知識蒸留（Knowledge Distillation）は，高性能なモデルが学習によって獲得した分類判断の構造や出力の傾向を，より小規模なモデルへと転移することを目的とした学習手法である．この概念は，Hinton ら [6] によってニューラルネットワークを対象として提案されたが，本質的には「教師モデルの予測分布を学習信号として利用する枠組み」であり，モデルの種類に依存しない一般的な考え方として捉えることができる．

一般に，高精度なモデルは多くの学習データや計算資源を必要とし，推論時間やモデルサイズの観点から実運用に制約が生じやすい．一方，小規模なモデルは計算効率に優れるものの，単純に正解ラベルのみを用いて学習した場合，分類性能が低下しやすいという課題を持つ．知識蒸留は，この両者の特性を補完する学習枠組みとして位置付けられる．

3.3.2 教師モデルと確率分布出力

知識蒸留では，教師モデル（Teacher Model）と生徒モデル（Student Model）の二つのモデルを用いる．教師モデルは，十分な学習条件の下で構築された高容量モデルであり，入力データ x に対して，各クラスに属する確率分布

$$\mathbf{p}_T(x) = (p_T(y = 1 \mid x), \dots, p_T(y = K \mid x)) \tag{3.10}$$

を出力する．

この確率分布には，正解クラスに対する確信度だけでなく，他クラスとの相対的な関係性も含まれている．例えば，誤分類されやすいクラス間では確率が近接し，判別が容易なクラスでは確率分布が鋭くなる傾向がある．このような分布構造は，教師モデルがデータから獲得した「暗黙的な判断基準」を反映していると解釈できる．

3.3.3 ニューラルネットワークにおける標準的知識蒸留

本節では，Hinton ら [6] が提案したニューラルネットワークを対象とする標準的な知識蒸留手法について述べる．この手法は知識蒸留の基礎的な枠組みであり，本研究で採用する手法の動機付けとして位置付けられる．なお，本研究の提案手法（XGBoost → XGBoost）では，KL ダイバージェンス最小化やロジット一致，生徒モデルの構造変更は行わず，教師の出力確率分布を**データ側の操作（top-m 展開とサンプル重み付け）**として利用する．

温度スケーリングによる分布の平坦化

標準的な知識蒸留では，教師モデルの出力確率分布が過度に尖鋭である場合に，生徒モデルにとって学習信号として有効に機能しない問題が生じる．そこで，温度パラメータ τ を用いた温度スケーリングが導入される [5].

ニューラルネットワークの出力層におけるロジット z_k（softmax 関数適用前の値）に対し，温度スケーリングを適用したクラス確率は次式で定義される：

$$\tilde{p}_T(y = k \mid x) = \frac{\exp(z_k/\tau)}{\sum_{j=1}^{K} \exp(z_j/\tau)}. \tag{3.11}$$

温度 $\tau > 1$ とすることで分布は平坦化され，クラス間の相対的な確信度が強調される．$\tau = 1$ のとき通常の softmax 出力と一致し，$\tau \to \infty$ で一様分布に近づく．

損失関数の構成

標準的な知識蒸留では，生徒モデルの学習において，正解ラベルに基づく損失（Hard Loss）と，教師モデルの出力分布に基づく損失（Soft Loss）を線形結合した目的関数を最小化する．

Hard Loss は，正解ラベル y_i と生徒モデルの出力分布 $\mathbf{p}_S(x_i)$ との交差エントロピーとして定義される：

$$\mathcal{L}_{\text{hard}} = \sum_{i=1}^{N} \ell_{\text{CE}}(y_i, \mathbf{p}_S(x_i)). \tag{3.12}$$

Soft Loss は，温度スケーリングを適用した教師分布 $\tilde{\mathbf{p}}_T(x_i)$ と生徒分布 $\tilde{\mathbf{p}}_S(x_i)$ との KL ダイバージェンスまたは交差エントロピーとして定義される：

$$\mathcal{L}_{\text{soft}} = \sum_{i=1}^{N} D_{\text{KL}}(\tilde{\mathbf{p}}_T(x_i) \| \tilde{\mathbf{p}}_S(x_i)). \tag{3.13}$$

最終的な目的関数は，両者の線形結合として

$$\mathcal{L}_{\text{KD}} = (1 - \alpha)\, \mathcal{L}_{\text{hard}} + \alpha\, \mathcal{L}_{\text{soft}} \tag{3.14}$$

と表される．ここで $\alpha \in [0, 1]$ は両損失の寄与度を調整する重み係数である．

3.3.4 決定木モデルへの適用における課題

前節で述べた標準的な知識蒸留は，ニューラルネットワークを前提として設計されている．特に，生徒モデルが損失関数を通じて教師分布との距離を直接最小化する（式 (3.13)）ためには，モデルの出力に対する勾配が連続的に定義されている必要がある．

しかし，XGBoost をはじめとする決定木ベースのモデルでは，以下の理由から標準的な知識蒸留をそのまま適用することが困難である．

第一に，XGBoost の学習過程は，特徴量空間における貪欲的な分割に基づいており，各分岐点では離散的な閾値判定によって木構造が構築される．この離散的な最適化過程において，教師モデルの連続的な確率分布を直接的に損失関数として組み込むことは，学習アルゴリズムの設計上想定されていない．

第二に，XGBoost の目的関数（式 (3.6)）は，正解ラベルと予測値の誤差に基づいて定義されており，KL ダイバージェンスや教師分布との交差エントロピーを損失関数として自然に導入する機構を持たない．

これらの制約を踏まえ，本研究では，教師モデルの出力確率分布を損失関数の監督対象としてではなく，XGBoost が標準的に備えるサンプル重み機構を通じて学習データの構成に間接的に反映させるアプローチを採用する．図 3.3 に，本研究で用いる XGBoost → XGBoost の知識蒸留の流れ（top-m 展開とサンプル重み付け）を示す．本図により，教師モデルの確率分布が **Top-m selection**，**Sample expansion**，**Sample weight** を介して生徒モデル学習へ反映されることを直感的に確認できる．この手法の具体的な定式化については，第 4 章にて述べる．

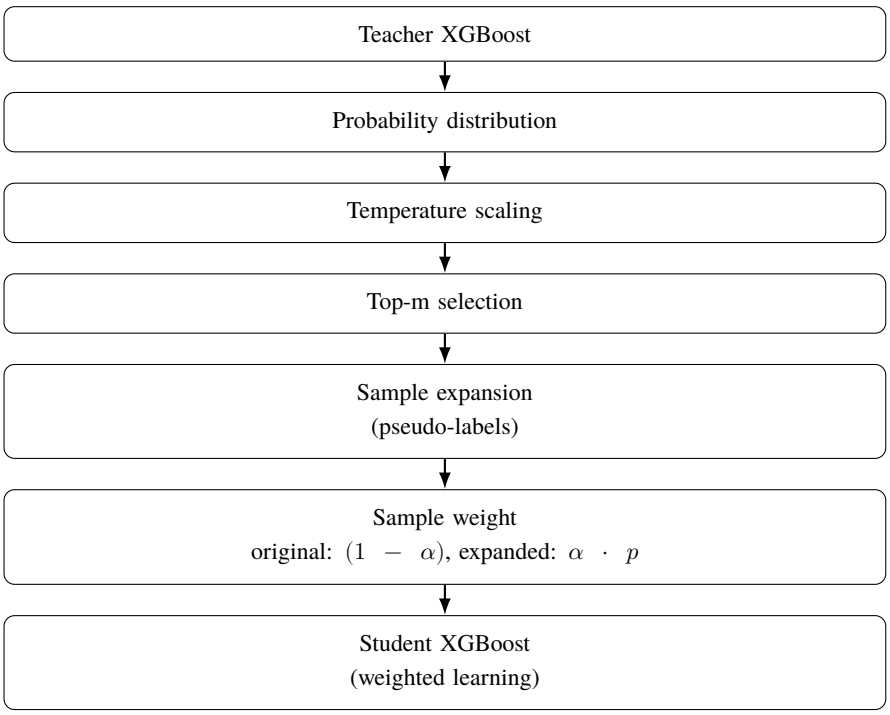

図 3.3: 本研究における知識蒸留の概念図（top-m 展開とサンプル重み）

第 4 章

提案手法

4.1 概要

本研究では，先行研究により確立された RGB 頻度分布を用いたトマト葉病害分類の枠組みを前提とし，その上で，勾配ブースティング決定木（GBDT）に基づく XGBoost に対する知識蒸留手法を提案する．

本研究の対象は，トマト葉の健康状態および複数の病害からなる計 10 クラスの分類問題である．先行研究では，トマト葉画像から抽出した RGB 頻度分布を特徴量とし，XGBoost による分類モデルが構築されている [13]．本研究では，この枠組みを基盤として採用し，以降の学習手法の拡張を行う．

従来，高い分類性能を有するモデルは，学習回数やモデル容量が大きくなる傾向があり，推論時間や計算コストの増大が課題となる．特に，農業分野における病害診断では，実環境での利用を想定した軽量かつ高速な推論モデルが求められる．

そこで本研究では，教師モデルおよび生徒モデルの双方に XGBoost を用いた知識蒸留の枠組みを構築する．具体的には，学習回数および木の深さが大きい高容量な XGBoost を教師モデルとし，モデル容量を制限した小容量な XGBoost を生徒モデルとして設定する．教師モデルが出力する 10 クラスの確率分布を学習信号として利用し，生徒モデルへの知識転移を行う．

第 3 章で述べたとおり，一般的な知識蒸留はニューラルネットワークを対象としてロジットや KL ダイバージェンスに基づいて定式化されるが，XGBoost の離散的な木構造に基づく学習機構では，教師分布を損失関数に直接組み込むことが困難である．そこで本研究では，XGBoost が標準的に備えるサンプル重み機構を活用し，教師モデルの確率分布をデータ構成およびサンプル重みとして間接的に反映させる蒸留手法を採用する．

本章では，使用データ，問題設定と入出力定義，教師モデルおよび生徒モデルの設計，ならびに XGBoost 同士の知識蒸留に基づく学習手法について説明する．

4.2 使用データ

本研究では，Kaggle により公開されている「Tomato leaf disease detection using CNN」データセットを使用する [3]．本データセットは，トマト葉の病害検出を目的として構築されたものであり，トマト葉画像を複数の病害クラスに分類する研究において広く利用されている．

Kaggle は，データ分析および機械学習分野における代表的なコンペティションプラットフォームであり，公開データセットを用いた分析やモデル評価が広く行われていることが知られている [12]．本研究では，当該データセットを研究目的の範囲内で利用している．

4.2.1 クラスとラベルの定義

本研究では，「Tomato leaf disease detection using CNN」データセットに含まれる 10 種類のクラスを用いる．各クラスには 0 から 9 の整数ラベルを割り当て，ラベル 0 を Healthy，ラベル 1–9 を Disease と定義する．具体的なクラスとラベルの対応は以下の通りである．

表 4.1: クラスとラベルの対応

ラベル	クラス名
0	Healthy（健全葉）
1	Bacterial Spot（斑点細菌病）
2	Early Blight（早期病害）
3	Late Blight（疫病）
4	Leaf Mold（トマト葉かび病）
5	Septoria Leaf Spot（褐斑病）
6	Spider Mites（ハダニ類）
7	Target Spot（ターゲットスポット病）
8	Tomato Mosaic Virus（トマトモザイク病）
9	Tomato Yellow Leaf Curl Virus（トマト黄化葉巻病）

各病害クラスの詳細についてはすでに第 2 章で説明した．

4.2.2 データセットの特徴

使用する「Tomato leaf disease detection using CNN」データセットは，以下の特徴を有する．

- トマト葉に関する健康状態および複数の病害が，10 クラスに分類されている．
- 異なる撮影角度や照明条件下で取得された画像が含まれており，実環境におけるばらつきを反映している．
- 画像サイズは 256×256 に統一されており，RGB カラー画像として提供されている．

4.2.3 データ前処理の全体像

本研究では，トマト葉画像をそのまま学習モデルに入力するのではなく，複数段階の前処理を施した上で，RGB 頻度分布として特徴量化を行う．

これは，本研究が画像分類を目的とする深層学習手法ではなく，テーブル形式の特徴量に基づく勾配ブースティングモデル（XGBoost）を用いるためである．すなわち，画像データを明示的に数値特徴量へ変換することで，計算コストを抑えた学習を可能とすることを目的としている．

前処理の流れとしては，まず原画像に対して背景透過処理を行い，対象であるトマト葉領域のみを抽出する．次に，背景が除去された画像に含まれる画素を対象として，RGB 各成分の出現頻度を集計し，正規化した頻度分布ベクトルを作成する [11].

4.2.4 背景透過処理

RGB 頻度分布は，画像全体に含まれる色成分の出現傾向を集計する特徴量である．そのため，葉領域以外の背景に由来する色情報が含まれる場合，病害に起因する色分布の差異が相対的に弱められる可能性がある．

本研究では，このような背景由来ノイズの影響を抑制する目的で，トマト葉領域と背景領域を分離し，葉領域のみを対象として特徴量を算出する．具体的には，背景領域を透過したアルファチャネル付き画像を生成し，後続の特徴量算出に用いる．

この処理により，入力特徴量が主に葉領域の色分布を反映するようになり，特徴分布の安定化が期待される [11].

4.2.5 アルファマスクを用いた RGB 頻度分布の算出

背景透過後の画像は，対象領域を示すアルファチャネルを含む．本研究では，このアルファチャネルをマスクとして利用し，トマト葉領域に対応する画素のみを抽出する．

具体的には，アルファ値が 0 より大きい画素を対象領域とみなし，対応する RGB 成分のみを集計対象とする．これにより，背景領域に由来する画素は RGB 頻度分布の算出から除外される．

抽出された対象領域の画素集合に対して，R，G，B 各成分について 0〜255 の 256 階調に分割した頻度分布を算出する．各頻度分布は，画像中の画素数に依存しない特徴量とするため，確率分布として正規化を行う．

このように，アルファマスクを用いることで，葉領域に固有な色分布のみを反映した RGB 頻度分布特徴量を構成することが可能となる [11].

4.2.6 特徴量ベクトルの構成

得られた R，G，B 各成分の頻度分布（各 256 次元）を結合し，最終的に 768 次元の特徴量ベクトルとして構成する．本研究では，この 768 次元ベクトルを 1 枚の画像に対応する入力特徴量とする．

本特徴量は，画像サイズや画素数の違いに依存しないため，異なる撮影条件下で取得された画像に対しても一定の安定性を有すると考えられる [11].

4.2.7 対数変換

RGB 頻度分布特徴量に対して，以下の対数変換を適用する：

$$X' = \log(1 + X). \tag{4.1}$$

RGB 頻度分布は，特定の階調値に頻度が集中し，多くの階調値でゼロに近い値をとる傾向がある．この変換により，大きな頻度値のスケールが圧縮され，小さな頻度値の差異が相対的に保存される効果が得られる．また，$\log(1 + 0) = 0$ であるため，頻度ゼロの特徴量は変換後もゼロのまま保持される．

本変換は，データ分割後かつモデル学習前に，訓練データおよびテストデータの双方に対して適用する．

4.2.8 データの利用方法

前処理および対数変換によって得られた特徴量は，各画像につき 768 次元のベクトルとして構成される．本研究では，これらの特徴量を入力として，XGBoost による多クラス分類モデルを学習する．

このように，画像データをテーブル形式の特徴量へ変換することで，計算コストを抑えつつ，勾配ブースティングモデルによる学習を可能としている．

4.2.9 データの利用条件

使用した「Tomato leaf disease detection using CNN」データセットは，Kaggle の利用規約に基づき，研究目的の範囲内で利用している．また，データセット提供者への適切な引用を行い，公正かつ適切な利用を

心がけている．

4.2.10　データセット提供者への謝辞

本研究で使用したデータセット「Tomato leaf disease detection using CNN」の提供者である Pooja M. Deshpande 氏，Prathamesh H. Desai 氏，および Ramakanth Kumar P. 氏に対し，深く感謝の意を表する [3].

4.2.11　データの分割方法

各クラスに対して，訓練データおよび評価データが偏りなく含まれるようにデータ分割を行う．分割の際には乱数 seed（`data_seed=31`）を固定し，再現性を確保している．

本研究では，各クラスから訓練データ 770 枚，テストデータ 330 枚を抽出し，全体として訓練データ 7,700 枚，テストデータ 3,300 枚を用いる．教師モデルおよび生徒モデルの学習には同一のデータ分割を用いることで，モデル間の性能比較における公平性を担保する．

4.3　問題設定と入出力定義

本研究は，RGB 頻度分布を入力とし，トマト葉病害クラスを出力とする 10 クラス分類問題として定式化する．

4.3.1　入力特徴量

入力特徴量は，各トマト葉画像から算出した RGB 頻度分布に対数変換（式（4.1））を適用したものである．R，G，B 各成分について 0〜255 の階調値の出現頻度を集計し，正規化および対数変換を行った分布ベクトルを結合することで，768 次元の特徴量ベクトルとして XGBoost に入力する．

4.3.2　出力クラス

出力は，健康状態 1 クラスおよび病害 9 クラスからなる計 10 クラスである．学習モデルは，入力特徴量に対してこれら 10 クラスのいずれかを予測する．

4.4　提案手法の設計方針

本研究では，RGB 頻度分布に基づく XGBoost 分類器を基盤とし，モデルの軽量化と分類性能の両立を目的として，知識蒸留を導入する．

教師モデルおよび生徒モデルの双方に XGBoost を用いる点に本手法の特徴がある．学習反復回数や木の深さ（モデル容量）を変化させることで，高容量モデルが獲得した判断傾向を，低容量モデルへ転移することを目指す．

本研究で比較するモデルは以下の 3 種類である：

- **Teacher**：高容量な XGBoost（`num_boost_round=700`，`max_depth=5`）
- **Student-Base**：低容量な XGBoost（`num_boost_round=150`，`max_depth=3`）．知識蒸留を行わず，正解ラベルのみで学習したベースラインモデル
- **Student-KD**：Student-Base と同一のモデル容量のまま，教師確率分布を学習信号として取り込むモデル

4.5 知識蒸留に基づく学習手法

本節では，第 3 章第 3.3.4 節で述べた決定木モデルへの知識蒸留における課題を踏まえ，XGBoost の学習機構に適合する蒸留手法の具体的な設計を述べる．

4.5.1 教師確率分布の取得

教師モデルは，`multi:softprob` 目的関数を用いて学習されており，各入力 x_i に対して 10 クラスの確率分布

$$\mathbf{p}_T(x_i) = (p_T(y = 0 \mid x_i), \dots, p_T(y = 9 \mid x_i)) \tag{4.2}$$

を出力する．この確率分布を，訓練データ全体に対して取得し，以降の蒸留処理に用いる．

4.5.2 温度スケーリング

教師モデルの出力確率分布に対して，温度パラメータ τ を用いた温度スケーリングを適用し，分布の平坦化を行う．

XGBoost はニューラルネットワークのようにロジットを明示的に出力しないため，本研究では，出力確率に対して対数空間で温度スケーリングを適用する．具体的には，教師モデルの出力確率 $p_T(y = k \mid x)$ に対して，

$$\tilde{p}_T(y = k \mid x) = \frac{\exp(\log p_T(y = k \mid x)/\tau)}{\sum_{j=0}^{K-1} \exp(\log p_T(y = j \mid x)/\tau)} \tag{4.3}$$

により温度スケーリング後の分布を得る．$\tau > 1$ のとき分布は平坦化され，クラス間の相対的な確信度構造が強調される．本研究では $\tau = 2.0$ を用いる．

なお，式（4.3）は，$\log p$ を擬似的なロジットとみなし，温度パラメータで除算した上で再正規化を行う操作であり，確率出力のみが利用可能な場合の実用的な温度スケーリング手法である．

4.5.3 サンプル展開と重み付け（top-m）

第 3 章で述べたとおり，XGBoost は損失関数内部に教師分布を直接組み込むことが困難であるため，本研究では，教師モデルの確率分布情報をデータ構成の変更を通じて間接的に反映させる．

具体的には，各訓練サンプル x_i に対して，温度スケーリング後の教師分布 $\tilde{\mathbf{p}}_T(x_i)$ から確率の高い上位 m クラスを選択し，同一の特徴量 x_i を m 個のサンプルとして展開する．展開された各サンプルには，対応するクラスラベル k と，教師確率 $\tilde{p}_T(y = k \mid x_i)$ をサンプル重みとして付与する．

すなわち，上位 m クラスのインデックス集合を $\mathcal{M}_i = \{k_1, k_2, \dots, k_m\}$ ($\tilde{p}_T(y = k_1 \mid x_i) \geq \dots \geq \tilde{p}_T(y = k_m \mid x_i)$）とすると，各 $k \in \mathcal{M}_i$ に対して

$$(x_i,\ k,\ \tilde{p}_T(y = k \mid x_i)) \tag{4.4}$$

の三つ組（特徴量，ラベル，重み）を生成する．

この処理により，N 件の訓練データから $N \times m$ 件の展開サンプルが生成される．なお，上位 m 内での確率の再正規化は行わず，教師確率の絶対値をそのまま重みとして用いる．これにより，教師モデルの確信度の大小関係が保存される．

4.5.4 Hard / Soft 混合学習

生徒モデルの学習では，正解ラベルに基づく Hard Target と，前節で生成した教師モデル由来の Soft Target（top-m 展開サンプル）を併用する．

具体的には，元の訓練データ $\{(x_i, y_i)\}_{i=1}^{N}$ を Hard 部，top-m 展開により生成されたサンプル集合を Soft 部とし，両者を結合した拡張データセット上で XGBoost の学習を行う．

このとき，混合係数 $\alpha \in [0, 1]$ を用いて各部のサンプル重みを次のように設定する：

$$w_{\text{hard},i} = 1 - \alpha, \tag{4.5}$$

$$w_{\text{soft},i,k} = \alpha \cdot \tilde{p}_T(y = k \mid x_i), \quad k \in \mathcal{M}_i. \tag{4.6}$$

α が小さいほど正解ラベル（Hard Target）が支配的となり，α が大きいほど教師モデルの確率分布が学習により強く反映される．

結合後の拡張データセットは，XGBoost の `DMatrix` に対してラベルおよびサンプル重みを設定することで構築し，通常の学習アルゴリズムをそのまま適用する．これにより，XGBoost の学習機構を変更することなく知識蒸留を実現する．

4.5.5 提案手法のアルゴリズム

以上の処理に基づく提案手法の学習手順を Algorithm 1 に示す．

まず，訓練データ $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$ を用いて教師モデル T を学習し，各サンプル x_i に対する教師確率分布 $\mathbf{p}_T(x_i)$ を取得する．次に，温度 τ による温度スケーリング（式（4.3））を適用し，平坦化された分布 $\tilde{\mathbf{p}}_T(x_i)$ を得る．

続いて，各サンプルについて，$\tilde{\mathbf{p}}_T(x_i)$ の上位 m クラスの集合 $\mathcal{M}_i$ を選択し，各クラス $k \in \mathcal{M}_i$ に対して，特徴量 x_i を複製した上でラベルを k，重みを $\alpha \cdot \tilde{p}_T(y = k \mid x_i)$ とする Soft サンプルを生成する．同時に，正解ラベル y_i と重み $1 - \alpha$ を持つ Hard サンプルも作成する．

最後に，全サンプルの Hard 部と Soft 部を結合した拡張データセット $\mathcal{D}'$ を構築し，$\mathcal{D}'$ 上で生徒モデル S を学習する．これにより，教師モデルの判断傾向がサンプル重みを介して生徒モデルへ転移される．

Algorithm 1 XGBoost 間知識蒸留の学習手順

Require: 訓練データ $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$，温度 τ，混合係数 α，展開クラス数 m
Ensure: 学習済み生徒モデル S
  教師モデル T を $\mathcal{D}$ 上で学習する
  for $i = 1$ to N **do**
    教師確率分布 $\mathbf{p}_T(x_i)$ を取得する
    温度スケーリングにより $\tilde{\mathbf{p}}_T(x_i)$ を計算する（式（4.3））
    上位 m クラス $\mathcal{M}_i$ を選択する
    for $k \in \mathcal{M}_i$ **do**
      Soft サンプル $(x_i, k, \alpha \cdot \tilde{p}_T(y = k \mid x_i))$ を生成する
    end for
    Hard サンプル $(x_i, y_i, 1 - \alpha)$ を生成する
  end for
  Hard 部と Soft 部を結合し拡張データセット $\mathcal{D}'$ を構築する
  $\mathcal{D}'$ 上で生徒モデル S を学習する
  return S

4.6 ハイパーパラメータ

本研究で用いる主要なハイパーパラメータを以下に示す．なお，教師モデルと生徒モデルは同一の学習アルゴリズム（XGBoost）に基づくが，`num_boost_round` および `max_depth` を変化させることでモデル容量を制御する．

4.6.1 教師モデル（Teacher）

- `objective=multi:softprob`
- `eval_metric=mlogloss`
- `eta=0.2`
- `max_depth=5`
- `subsample=0.8`
- `colsample_bytree=0.8`
- `num_class=10`
- `num_boost_round=700`
- `seed=31`（固定，1 回のみ学習）

4.6.2 生徒モデル（Student-Base / Student-KD）

- `objective=multi:softprob`
- `eval_metric=mlogloss`
- `eta=0.2`
- `max_depth=3`
- `subsample=0.8`
- `colsample_bytree=0.8`
- `num_class=10`
- `num_boost_round=150`
- `seed`：5 種類の乱数 seed（31, 32, 33, 34, 35）を用いて実験を実施し，結果は平均値として整理する

4.6.3 知識蒸留パラメータ

蒸留に関するパラメータは，以下の範囲でグリッドサーチを行い，各組合せにおける性能を比較する．

- 温度：$\tau = 2.0$（固定）
- 混合係数：$\alpha \in \{0.01,\ 0.03,\ 0.05,\ 0.07,\ 0.09,\ 0.1\}$（6 水準）
- 展開クラス数：$m \in \{1,\ 2,\ 3\}$（3 水準）

これにより，$6 \times 3 = 18$ 通りのパラメータ組合せについて実験を行う．各組合せにつき 5 seeds で評価を行うため，合計 $18 \times 5 = 90$ 回の学習を実施する．

4.7 実験プロトコル

4.7.1 再現性の確保

本研究では，以下の方針により実験の再現性を確保する．

- **データ分割の固定**：`data_seed=31` を用いてデータ分割を行い，教師モデル・生徒モデルともに同一の訓練データ・テストデータを使用する．
- **教師モデルの固定**：教師モデルは `seed=31` で 1 回のみ学習し，全ての蒸留実験において同一の教師確率分布を使用する．
- **複数 seed による評価**：生徒モデル（Student-Base および Student-KD）は，5 種類の乱数 seed（31, 32, 33, 34, 35）を用いてそれぞれ学習を行い，評価指標の平均値をもって性能を報告する．

4.7.2 ベースラインとの比較方法

提案手法の有効性は，同一のモデル容量を持つ Student-Base の 5 seed 平均値をベースラインとし，Student-KD の各パラメータ組合せにおける 5 seed 平均値との差分（Δ）によって評価する．

4.8 評価指標

本研究では，提案手法の有効性を「分類性能の維持・向上」と「推論の高速化（計算コスト低減）」の両面から評価する．評価には以下の指標を用いる．

- 10 クラス分類としての性能指標（Accuracy，Macro-F1）
- 病害を見逃さない観点の指標（病害再現率：二値化 Recall）
- 推論時間指標（テストデータ全体に対する推論時間）
- Student-Base と Student-KD の差分（改善量 Δ）

なお，本研究では，多クラス分類において各クラスの予測確率を出力する設定を用いる（XGBoost における `multi:softprob`）．モデルは入力 x に対してクラス k の予測確率 $p_k(y \mid x)$ を出力し，最終的な予測クラス $\hat{y}$ は

$$\hat{y} = \arg\max_{k \in \{0,\ldots,K-1\}} p_k(y \mid x) \tag{4.7}$$

により決定する（$K = 10$）．

4.8.1 正答率（Accuracy）

正答率（Accuracy）は，テストデータにおける予測結果のうち，正しく分類できた割合である．テストデータ数を N，正解数を N_{correct} とすると，

$$\text{Accuracy} = \frac{N_{\text{correct}}}{N} \tag{4.8}$$

で定義される．

4.8.2 Macro-F1 スコア

本研究は 10 クラス分類であるため，クラス間の偏りの影響を抑えて全体傾向を把握する目的で，各クラスの F1 スコアを単純平均した macro-F1 を用いる．

クラス k に対する Precision / Recall を $\text{Precision}_k, \text{Recall}_k$ とすると，ここで TP_k はクラス k を正しく k と予測した数（True Positive），FP_k はクラス k ではないのに k と予測した数（False Positive），FN_k はクラス k であるのに k と予測できなかった数（False Negative）である．

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}, \qquad \text{Recall}_k = \frac{TP_k}{TP_k + FN_k} \tag{4.9}$$

であり，

$$\mathrm{F1}_k = \frac{2\,\mathrm{Precision}_k\,\mathrm{Recall}_k}{\mathrm{Precision}_k + \mathrm{Recall}_k} \tag{4.10}$$

で定義される．さらに，

$$\text{Macro-F1} = \frac{1}{K}\sum_{k=0}^{K-1} \mathrm{F1}_k \tag{4.11}$$

を macro-F1 とする（$K = 10$）[7].

4.8.3 病害再現率（二値化 Recall）

本研究では「病害を見逃さない」観点も重要であるため，Healthy（健康）と Disease（病害）に二値化した再現率も併記する．具体的には，ラベル 0 を Healthy，ラベル 1–9 を Disease とみなし，

$$y_{\text{bin}} = \mathbb{I}[y \neq 0], \qquad \hat{y}_{\text{bin}} = \mathbb{I}[\hat{y} \neq 0]$$

により二値化する．

このとき Disease（陽性）に対する再現率は

$$\mathrm{Recall}_{\text{disease}} = \frac{TP}{TP + FN} \tag{4.12}$$

で定義される．なお，本研究では Disease を陽性（positive）として扱い，二値分類における再現率（Recall）を病害再現率として用いる．ここで TP は「実際に Disease であるサンプルを Disease と予測した数」，FN は「実際に Disease であるサンプルを Healthy と誤予測した数」である．以降，この値を病害再現率と呼ぶ．

4.8.4 推論時間

本研究の目的の一つは，生徒モデルを軽量化し，推論の高速化および計算コスト低減を達成することである．そのため，分類性能に加えて推論時間を計測し評価に用いる．

推論時間 t_{infer} は，学習済みモデルに対してテストデータ全体（$N_{\text{test}} = 3{,}300$ 件）を入力し，`predict` により 10 クラスそれぞれの予測確率（各クラスに属する確率）を出力する処理に要した時間（秒）である．

なお，推論時間は各 seed ごとに計測し，最終的な結果は 5 seed の平均値として整理する．また，訓練時間についても補助的に計測し，蒸留に伴う計算コストの変化を確認する．

4.8.5 Student-Base と Student-KD の改善量（差分指標）

提案手法の有効性は，同一のモデル容量を持つ Student-Base と Student-KD を比較し，蒸留によって性能がどの程度変化したかで評価する．

各評価指標 M（Accuracy，Macro-F1，病害再現率）に対して，

$$\Delta M = \overline{M}(\text{Student-KD}) - \overline{M}(\text{Student-Base}) \tag{4.13}$$

を改善量として定義する．ここで $\overline{M}$ は 5 seed の平均値を表す．

推論時間については，

$$\Delta t_{\text{infer}} = \bar{t}_{\text{infer}}(\text{Student-KD}) - \bar{t}_{\text{infer}}(\text{Student-Base}) \tag{4.14}$$

を定義する．

このような差分による性能評価は，モデル条件の違いによる影響を明確化する目的で用いられる手法である [10].

第 5 章

実験

5.1 実験概要

本章では，前章で提案した RGB 頻度分布に基づく XGBoost 分類モデルおよび XGBoost 同士による知識蒸留手法の有効性を，実験的に検証する．

実験では，Kaggle により公開されている「Tomato leaf disease detection using CNN」データセットを用い，背景除去後のトマト葉画像から算出した RGB 頻度分布を入力特徴量として，10 クラスの病害分類を行う．

評価は，高容量な教師モデル（Teacher），軽量な生徒モデル（Student-Base），および知識蒸留を適用した生徒モデル（Student-KD）の 3 種類を対象として行う．特に，Student-Base と Student-KD はモデル容量を同一に保った上で，学習方法のみを変更しており，知識蒸留による効果を純粋に比較できる構成としている．

本章ではまず，実験条件およびハイパーパラメータ設定を示し，続いて，分類性能（Accuracy，Macro-F1，病害再現率）と計算効率（推論時間）に基づいて各モデルの性能を比較・分析する．さらに，知識蒸留パラメータ（混合係数 α，展開クラス数 m）が性能に与える影響を網羅的に検討する．

5.2 実験条件

本節では，本研究において実施した各実験の共通条件について述べる．

5.2.1 使用データ

実験には，Kaggle により公開されている「Tomato leaf disease detection using CNN」データセットを用いる．本データセットは，トマト葉の健康状態および複数の病害を含む 10 クラスの画像データから構成されている．

本研究では，画像を直接入力として用いるのではなく，前章で述べた方法により，背景除去後のトマト葉画像から RGB 頻度分布を算出し，対数変換を適用した上で学習用の特徴量として利用する．

5.2.2 データ分割方法

データ分割は，クラス間の偏りを避けるため，各クラスから同数のサンプルを抽出する方法を採用する．具体的には，各クラスにつき訓練データとして 770 枚，テストデータとして 330 枚を用い，全体として訓練データ 7,700 枚，テストデータ 3,300 枚を構成する．

サンプルの抽出およびシャッフルには乱数 seed（`data_seed=31`）を固定し，教師モデル・生徒モデル間

で同一のデータ分割を用いる．

5.2.3 モデル構成

本研究では，すべての分類モデルに XGBoost を用いる．目的関数には，多クラス分類に対応した `multi:softprob` を採用し，各入力に対して 10 クラスの確率分布を出力する．

実験では，以下の 3 種類のモデルを用いる．

- **教師モデル（Teacher）**：高容量なモデルとして学習し，生徒モデル学習時の教師信号を生成する．
- **生徒モデル（Student-Base）**：モデル容量を抑えた軽量モデルであり，正解ラベル（Hard Target）のみを用いて学習する．
- **生徒モデル（Student-KD）**：Student-Base と同一のモデル容量を持ち，教師モデルの確率分布（Soft Target）をサンプル重みとして取り込む．

Teacher と Student-Base / Student-KD は，学習反復回数および決定木の深さを変えることでモデル容量を制御しており，Student-Base と Student-KD の比較により，知識蒸留の効果を検証する．

5.2.4 実験環境

実験は同一の計算環境上で実施し，すべてのモデルに対して同一条件で学習および評価を行う．これにより，モデル構成および学習手法の違いのみが評価結果に反映されるよう配慮する．

5.2.5 ハイパーパラメータ設定

本研究で行う各実験における主要なハイパーパラメータ設定を以下に示す．これらの値は，先行研究および予備実験の結果を踏まえて決定した．

表 5.1: 教師モデル（Teacher）のハイパーパラメータ

パラメータ名	値
`eta`	0.2
`max_depth`	5
`subsample`	0.8
`colsample_bytree`	0.8
`num_boost_round`	700
`seed`	31（固定）

教師モデルは，比較的高いモデル容量を持つ分類器として構成し，知識蒸留における参照モデルとして用いる．教師モデルの反復回数については，予備実験として `num_boost_round` を 50 から 900 まで変化させて評価を行い，分類性能が高くかつ安定していた 700 を採用した．

表 5.3 に示すとおり，知識蒸留に関するパラメータは $6 \times 3 = 18$ 通りの組合せについてグリッドサーチを行い，各組合せにつき 5 seeds で評価した．

5.3 ベースラインの確認

実験に先立ち，Teacher および Student-Base の基本性能を確認する．表 5.4 に，5 seed 平均による分類性能および推論時間を示す．

表 5.2: 生徒モデル（Student-Base / Student-KD）のハイパーパラメータ

パラメータ名	値
`eta`	0.2
`max_depth`	3
`subsample`	0.8
`colsample_bytree`	0.8
`num_boost_round`	150
`seed`	31, 32, 33, 34, 35（5 種類）

表 5.3: 知識蒸留に関するパラメータ設定

パラメータ名	値
温度 τ	2.0（固定）
混合係数 α	$\{0.01,\ 0.03,\ 0.05,\ 0.07,\ 0.09,\ 0.1\}$
展開クラス数 m	$\{1,\ 2,\ 3\}$

表 5.4: Teacher と Student-Base の性能比較（5 seed 平均）

モデル	Accuracy	Macro-F1	病害再現率	推論時間 [秒]
Teacher	0.8297	0.8288	0.9892	0.1349
Student-Base	0.7978	0.7969	0.9888	0.0175

Teacher は Student-Base に対して Accuracy で約 3.2 ポイント，Macro-F1 で約 3.2 ポイント高い分類性能を示すが，推論時間は約 7.7 倍を要する．この性能差と計算コストの乖離が，知識蒸留による軽量モデルの性能改善を検討する動機となっている．

なお，教師モデルは seed を固定して 1 回のみ学習しているため，表の値は単一の結果である．

5.4 知識蒸留パラメータの網羅的評価

本節では，$\alpha \in \{0.01,\ 0.03,\ 0.05,\ 0.07,\ 0.09,\ 0.1\}$，$m \in \{1,\ 2,\ 3\}$ の全 18 通りのパラメータ組合せに対して，Student-KD の性能を評価する．

各組合せについて 5 seed の平均値を算出し，Student-Base（5 seed 平均）との差分 Δ を報告する．

5.4.1 全パラメータ組合せの結果

表 5.5 に，全 18 通りの組合せにおける Student-KD の Student-Base に対する性能差分を Macro-F1 の降順で示す．

表 5.5 から，以下の傾向が確認できる．

第一に，全 18 通りの組合せにおいて，推論時間が Student-Base に対して 2.8%〜12.4% 短縮されている．すなわち，知識蒸留の適用により，パラメータ設定にかかわらず推論時間が一貫して短縮される傾向が認められる．

第二に，分類性能（Accuracy，Macro-F1）の面では，18 通りのうち 4 通りの組合せにおいて Student-Base を上回る結果が得られた．特に $\alpha = 0.03,\ m = 2$ の組合せでは，Accuracy・Macro-F1 ともに +0.36% の改善を示し，全組合せ中で最良の分類性能改善を達成した．

表 5.5: Student-KD の Student-Base に対する性能差分（Δ，5 seed 平均，Macro-F1 降順）

α	m	ΔAccuracy	ΔMacro-F1	ΔRecall	Δ 推論時間
0.03	2	+0.36%	+0.36%	+0.05%	−10.09%
0.03	3	+0.07%	+0.10%	+0.05%	−12.39%
0.01	3	+0.08%	+0.10%	−0.02%	−7.39%
0.1	1	+0.05%	+0.06%	−0.01%	−7.38%
0.09	2	−0.01%	+0.01%	+0.01%	−10.77%
0.09	3	−0.04%	−0.03%	+0.02%	−10.15%
0.07	1	−0.05%	−0.04%	+0.01%	−3.21%
0.07	2	−0.04%	−0.05%	+0.04%	−3.55%
0.01	2	−0.08%	−0.07%	−0.01%	−6.08%
0.03	1	−0.10%	−0.07%	+0.07%	−10.35%
0.07	3	−0.10%	−0.09%	−0.06%	−10.37%
0.1	3	−0.10%	−0.09%	+0.01%	−2.83%
0.01	1	−0.11%	−0.10%	+0.04%	−11.41%
0.05	1	−0.11%	−0.11%	−0.02%	−3.80%
0.05	2	−0.17%	−0.16%	+0.04%	−8.34%
0.05	3	−0.22%	−0.21%	+0.01%	−10.70%
0.1	2	−0.32%	−0.30%	+0.03%	−11.60%
0.09	1	−0.46%	−0.44%	+0.01%	−8.38%

第三に，病害再現率については，全組合せを通じて ±0.07% 以内の変動に収まっており，知識蒸留の適用が病害の見逃し率に実質的な影響を与えないことが確認された．

5.4.2 混合係数 α の影響

本節では，混合係数 α が Student-KD の性能に与える影響について分析する．

表 5.5 の結果を α の観点から整理すると，分類性能の正の改善が見られた組合せは，いずれも α が比較的小さい領域（$\alpha = 0.01$〜0.03）に集中していることが分かる．一方，$\alpha = 0.05$ 以上では分類性能が低下する傾向が強まり，$\alpha = 0.09$（$m = 1$）では Macro-F1 が −0.44% と最大の低下を示した．

この傾向は，以下のように解釈できる．α が大きくなると，教師モデルの確率分布に基づく Soft Target の重みが増大し，正解ラベルに基づく Hard Target の寄与が相対的に低下する．XGBoost の木構造は各分岐において離散的な閾値判定を行うため，Soft Target の確率的な情報を過度に重視した場合，分岐条件の精度が劣化する可能性がある．

α を小さく設定することで，Hard Target が学習の主体を維持しつつ，教師分布の情報が補助的に作用する構成となり，結果として分類性能の劣化が抑えられたと考えられる．

5.4.3 展開クラス数 m の影響

次に，展開クラス数 m が性能に与える影響について分析する．

推論時間に着目すると，m の増大に伴い推論時間の短縮幅が拡大する傾向が認められる．$m = 1$ では平均的に 3%〜11% の短縮であるのに対し，$m = 2$〜3 では 6%〜12% 程度の短縮が得られている．

分類性能については，最良の結果は $m = 2$ で得られている（$\alpha = 0.03, m = 2$）．$m = 3$ においても正の

改善が見られる組合せが存在するが（$\alpha = 0.03, m = 3$：ΔF1 $= +0.10\%$），全体的には $m = 2$ が最も安定した結果を示した．

$m = 1$ の場合は，教師分布の最上位クラスのみを用いるため，展開による情報量が限定的である一方，$m = 3$ では低確率クラスの情報も含まれるため，ノイズとして作用する可能性がある．$m = 2$ は，教師モデルの判断を適度に反映しつつ，ノイズの混入を抑える設定としてバランスが良いと考えられる．

5.5 最良条件における 3 モデルの比較

前節のグリッドサーチの結果，分類性能の改善が最大であった $\alpha = 0.03$，$m = 2$ の条件を最良条件として選定し，Teacher，Student-Base，Student-KD の 3 モデルを比較する．

5.5.1 分類性能の比較

表 5.6 に，最良条件における 3 モデルの分類性能を示す．

表 5.6: 3 モデルの分類性能比較（最良条件：$\alpha = 0.03$，$m = 2$，5 seed 平均）

モデル	Accuracy	Macro-F1	病害再現率
Teacher	0.8297	0.8288	0.9892
Student-Base	0.7978	0.7969	0.9888
Student-KD	0.8007	0.7997	0.9893
Δ（KD $-$ Base）	$+0.0028$	$+0.0028$	$+0.0005$

Student-KD は，Student-Base に対して Accuracy で $+0.28$ ポイント，Macro-F1 で $+0.28$ ポイントの改善を示した．病害再現率についても $+0.05$ ポイントの微増が見られ，病害の見逃しが増加していないことが確認された．

改善幅は小さいものの，モデル構造を一切変更せず，学習データの構成のみを変更することで性能改善が得られた点は，手法の実用的価値を示すものである．

5.5.2 推論時間の比較

表 5.7 に，最良条件における 3 モデルの計算時間を示す．

表 5.7: 3 モデルの計算時間比較（最良条件：$\alpha = 0.03$，$m = 2$，5 seed 平均）

モデル	訓練時間 [秒]	推論時間 [秒]	Δ 推論時間
Teacher	172.19	0.1349	—
Student-Base	34.12	0.0175	—
Student-KD	55.72	0.0157	-10.09%

推論時間に着目すると，Student-KD は Student-Base に対して約 10.1% の短縮を示した．Student-Base の推論時間は Teacher に対して既に大幅に短い（約 7.7 分の 1）が，知識蒸留の適用によりさらなる高速化が得られている．

一方，訓練時間は Student-Base の 34.12 秒から 55.72 秒へと約 63% 増加している．これは，top-m 展開により訓練データ数が N から $N + N \times m$（本条件では $7{,}700 + 7{,}700 \times 2 = 23{,}100$ 件）に増大するためである．ただし，訓練は事前に一度だけ行う処理であり，実運用時の推論コストに影響しないため，本研究の目的に照らして許容範囲であると考えられる．

5.5.3 推論時間短縮の考察

知識蒸留により推論時間が短縮されるという結果は，知識蒸留の典型的な効果（精度改善）とは異なる側面であり，本研究において特に興味深い発見である．

この推論時間短縮の原因を検討するため，Student-Base と Student-KD（最良条件：$\alpha = 0.03$，$m = 2$）の決定木構造を定量的に比較した．具体的には，学習済みモデルに含まれる全決定木（150 ラウンド × 10 クラス = 1,500 本）の構造統計量を算出するとともに，`model.save_model()` により保存したモデルファイルのサイズを比較した．いずれも 5 seed 平均で評価した．結果を表 5.8 に示す．

表 5.8: Student-Base と Student-KD の決定木構造比較（5 seed 平均）

指標	Student-Base	Student-KD	Δ
モデルサイズ [KB]	1801.6	1805.8	+0.23%
平均最大深さ	3.000	3.000	±0
平均葉ノード数	7.661	7.682	+0.28%
平均葉重み絶対値	0.0643	0.0640	−0.40%
平均分岐 gain	7.426	7.373	−0.72%
最大分岐 gain	16.985	16.901	−0.49%

表 5.8 より，モデルファイルサイズは Student-KD の方がわずかに大きく（+0.23%），木の深さおよび葉ノード数にも実質的な差は認められなかった．これは，`max_depth=3` という制約により木の形状が上限に達しているためと考えられる．

一方で，分岐 gain の平均値が −0.72%，葉ノード重みの絶対値が −0.40% と，いずれも Student-KD においてわずかに小さい値を示した．分岐 gain は各分岐点における損失削減量を表し，葉ノード重みは各葉ノードの出力値の大きさを表す．これらの結果は，Student-KD の決定木が個々の分岐や葉ノードにおいてより穏やかな判定を行う傾向を持つことを示唆している．

ただし，これらの差はいずれも 1% 未満と小さいものの，本研究における推論時間はミリ秒オーダの値であるため，構造指標のわずかな変化が相対的には推論時間短縮として観測される可能性がある．

また，推論時間短縮の効果自体は，全 18 通りのパラメータ組合せにおいて一貫して観測されており（表 5.5），再現性のある頑健な傾向であることが確認された．

5.6 考察

5.6.1 本研究の実験結果のまとめ

実験の結果，XGBoost 同士の知識蒸留による分類性能の改善は全体として限定的であることが明らかとなった．18 通りのパラメータ組合せのうち，分類性能が Student-Base を上回ったのは 4 通りであり，最良条件（$\alpha = 0.03$，$m = 2$）においても改善幅は Accuracy・Macro-F1 ともに +0.36% にとどまった．

一方で，推論時間については全組合せで一貫した短縮が確認され，最良条件では約 10% の高速化が得られた．また，病害再現率はすべての組合せでほぼ維持されており，蒸留による病害の見逃し増加は認められなかった．

5.6.2 分類性能の改善が限定的である理由

XGBoost 同士の知識蒸留において分類性能の改善が限定的であった理由として，決定木の学習機構に起因する構造的な制約が考えられる．

第 3 章で述べたとおり，ニューラルネットワークにおける知識蒸留では，教師モデルの確率分布を KL ダイバージェンスや交差エントロピーを通じて連続的に最適化することが可能である．生徒モデルの出力層は教師分布に直接近づくよう勾配が伝播し，クラス間の相対的な関係情報が効率的に転移される．

一方，XGBoost の学習過程は，特徴量空間における離散的な分割に基づいており，各分岐点では閾値判定による貪欲的な最適化が行われる．本研究では教師分布をサンプル重みとして間接的に反映させているが，この方式では分布の連続的な構造情報が離散化されて失われやすく，ニューラルネットワークにおける蒸留と同等の知識転移効果を得ることは原理的に困難であると考えられる．

また，α が大きい設定では Soft Target の重みが過度になり，学習が不安定化して性能が低下する傾向が観測された．これは，XGBoost の各分岐判定が離散的であるために，連続的な確率情報の過剰な注入が逆効果となることを示唆している．

5.6.3 推論時間短縮の意義

本研究において最も顕著な成果は，知識蒸留の適用により推論時間が一貫して短縮された点である．この効果は，全 18 通りのパラメータ組合せにおいて再現性をもって観測されており，特定のパラメータ設定に依存しない頑健な傾向であることが確認された．

決定木構造の比較結果（表 5.8）からは，木の深さやノード数，モデルファイルサイズといった形状面での有意な差は確認されなかったが，分岐 gain や葉ノード重みにはわずかな低下が観測された．これらの変化は，Student-KD における判定が全体として穏やかになる傾向を示しており，ミリ秒オーダの推論時間においては，こうした微小な差異が相対的な時間短縮として現れる可能性がある．

推論時間の短縮は，農業分野における実運用を想定した場合に重要な意義を持つ．エッジデバイスやスマートフォンなど，計算資源が限られた環境では，わずかな推論時間の削減であっても，大量の画像を処理する際には累積的な効果が期待される．

本研究の結果は，XGBoost 同士の知識蒸留が，分類精度向上を主目的とする手法というよりも，推論コスト削減を目的とした軽量化・高速化手法として有効に機能し得ることを示唆している．

5.6.4 本研究の限界と今後の展望

本研究では，教師モデルおよび生徒モデルの双方に XGBoost を用いたため，決定木モデルの学習機構に起因する制約から，分類性能の大幅な改善は得られなかった．今後は，異なるモデル構造間（例えば XGBoost から MLP への蒸留）における知識転移の有効性について検討することが考えられる．

また，本研究で用いた RGB 頻度分布特徴量に加え，特徴量設計の工夫やデータ拡張手法との組み合わせを検討することで，蒸留効果のさらなる向上が期待される．

第 6 章

結論

本研究では，トマト葉画像を対象とした病害 10 クラス分類問題に対し，XGBoost 同士による知識蒸留手法を構築し，その有効性および適用可能性について基礎的な検討を行った．

先行研究において有効性が示された RGB 頻度分布と XGBoost を用いた分類枠組みを基盤とし，高容量な教師モデル（`max_depth=5`，`num_boost_round=700`）が出力するクラス確率分布を，サンプル展開およびサンプル重み付けによって低容量な生徒モデル（`max_depth=3`，`num_boost_round=150`）へ転移する Teacher–Student 型の学習枠組みを構築した．混合係数 α（6 水準）および展開クラス数 m（3 水準）からなる計 18 通りのパラメータ組合せについて，各 5 seed による体系的な実験を実施した．

実験の結果，以下の知見が得られた．

第一に，分類性能の改善は全体として限定的であることが確認された．18 通りの組合せのうち，Student-Base を上回る分類性能を示したのは 4 通りにとどまり，最良条件（$\alpha = 0.03$，$m = 2$）においても，Accuracy および Macro-F1 の改善幅はいずれも $+0.36\%$ にとどまった．この結果は，XGBoost の離散的な決定木構造に基づく学習機構が，教師モデルの連続的な確率分布情報を十分に活用しきれないことに起因すると考えられる．

第二に，推論時間については，全 18 通りのパラメータ組合せにおいて一貫した短縮が観測された．推論時間の短縮幅は 2.8%〜12.4% の範囲に分布し，最良条件では約 10% の高速化が得られた．決定木構造およびモデルファイルサイズの詳細な比較から，木の深さやノード数，モデルサイズといった形状的な差異は限定的であることが確認されたが，分岐 gain や葉ノード重みにはわずかな低下が観測された．本研究の推論時間はミリ秒オーダであるため，こうした微小な構造変化が相対的な推論時間の短縮として現れたものと考えられる．

第三に，病害再現率は全組合せを通じて $\pm 0.07\%$ 以内の変動に収まり，知識蒸留の適用が病害の見逃し率に実質的な影響を与えないことが確認された．

以上の結果から，XGBoost 同士の知識蒸留は，分類精度の大幅な向上を目的とする手法としては限界があるものの，モデル構造を変更することなく推論時間を短縮する手段として，一定の有効性を持つことが示された．特に，小さな混合係数（$\alpha = 0.01$〜0.03）と適度な展開クラス数（$m = 2$）の組合せにおいて，分類性能を維持しつつ推論時間を削減できる点は，実運用を想定した応用上の利点である．

本研究では，教師モデルおよび生徒モデルの双方に XGBoost を用いたが，決定木モデルの学習機構上の制約により，分類性能の改善は限定的であった．今後の研究として，以下の方向性が考えられる．

第一に，異なるモデル構造間での知識蒸留の検討が挙げられる．例えば，XGBoost を教師モデルとし，MLP（多層パーセプトロン）などのニューラルネットワークを生徒モデルとする構成では，教師分布を連続的に最適化できるため，より効果的な知識転移が期待される．

第二に，推論時間短縮の機構について，より詳細な分析を行う余地がある．本研究では，決定木構造やモデルファイルサイズに有意な差がないにもかかわらず，一貫した推論時間短縮が観測されたことから，サ

ンプル重み付けが XGBoost の内部計算過程に与える影響について，さらなる検討が必要である．

第三に，特徴量設計やデータ拡張手法との組み合わせについても，検討の余地がある．本研究では RGB 頻度分布を入力特徴量として用いたが，異なる特徴表現の導入や学習データの多様化により，知識蒸留の効果が変化する可能性がある．

第 7 章

謝辞

本研究を進めるにあたり，多くの方々から多大なるご支援とご指導を賜りました．ここに深く感謝の意を表します．

まず，本研究を通して終始丁寧にご指導いただきました指導教員北栄輔教授に，心より御礼申し上げます．ご多忙の中，貴重なお時間を割いてご助言・ご指導いただき，研究の方向性や議論の進め方に関して多くの示唆を賜りました．そのおかげで，学部卒業研究としての取り組みを最後まで進めることができました．

次に，研究室の先輩方には，日頃の議論や助言を通じて多くの学びを得ました．実験設計や結果の整理に関する具体的なアドバイスをいただき，研究をより着実に進める上で大きな支えとなりました．

また，家族には，日常生活の面から温かく支えてもらい，学業と研究に集中できる環境を整えてもらいました．ここまで学びを続けられたのは家族の理解と支援のおかげです．心より感謝いたします．

最後に，本研究に関わってくださったすべての皆様に，改めて御礼申し上げます．

2026 年 2 月

名古屋大学情報学部自然情報学科複雑システム系

梁　媛源

参考文献

[1] Leo Breiman, Jerome H. Friedman, Richard A. Olshen, Charles J. Stone. *Classification and Regression Trees*. Wadsworth, 1984.

[2] Tianqi Chen, Carlos Guestrin. "XGBoost: A Scalable Tree Boosting System". In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794.

[3] Pooja M. Deshpande, Prathamesh H. Desai, Ramakanth Kumar P. *Tomato Leaf Disease Detection Using CNN*. Kaggle Dataset. (参照日:2026/2/9). 2023. URL: `https://www.kaggle.com/poojadeshpande/tomato-leaf-disease-detection`.

[4] Jerome H. Friedman. "Greedy Function Approximation: A Gradient Boosting Machine". In: *Annals of Statistics* 29.5 (2001), pp. 1189–1232.

[5] Chuan Guo, Geoff Pleiss, Yu Sun, Kilian Q. Weinberger. "On Calibration of Modern Neural Networks". In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. Vol. 70. Proceedings of Machine Learning Research. 2017, pp. 1321–1330.

[6] Geoffrey Hinton, Oriol Vinyals, Jeff Dean. *Distilling the Knowledge in a Neural Network*. arXiv preprint arXiv:1503.02531. 2015.

[7] Andreas C. Müller. *Python* **ではじめる機械学習：***scikit-learn* **で学ぶ特徴量エンジニアリングと機械学習の基礎**. オライリー・ジャパン, 2022, pp. 270–278. ISBN: 9784873117980.

[8] Marina Sokolova, Guy Lapalme. "A systematic analysis of performance measures for classification tasks". In: *Information Processing & Management* 45.4 (2009), pp. 427–437.

[9] 根本 久, 矢口 行雄. **決定版 植物の病害虫百科 ― 植物の病害虫その知識と予防**. Gakken, 2012. ISBN: 9784054052536.

[10] 馬場 優大, 藤生 慎, 森崎 裕磨. "ニューラルネットワークを用いた下水道管渠の緊急度予測モデルの提案―ハイパーパラメータの変更による精度比較―". In: *AI*・**データサイエンス論文集** 3.J2 (2022), pp. 1003–1009.

[11] 湯浅 南穂. "機械学習を用いたトマトの褐斑病診断". 卒業論文. 名古屋大学 情報学部, 2024.

[12] 門脇 大輔, 阪田 隆司, 保坂 桂佑, 平松 雄司. *Kaggle* **で勝つデータ分析の技術**. 技術評論社, 2019, pp. 2–9. ISBN: 978-4-297-10843-4.

[13] 矢賀 天大. "RGB 頻度分布によるトマトの葉の病害診断の改良". 卒業論文. 名古屋大学 情報学部, 2025.

[14] 日比 忠明, 大杉 立, 堤 伸浩. **植物病理学 II ― 感染生理・疫学・植物保護**. 朝倉書店, 2022. ISBN: 9784254405736.

[15] 農林水産技術会議. *AI* **を活用した病害虫診断技術の開発**. 2022. URL: `https://www.affrc.maff.go.jp/docs/project/pdf/seika/2022/r4_seikashu_02.pdf`.

[16] 農林水産省. **スマート農業をめぐる情勢について**. 2025. URL: `https://www.maff.go.jp/j/kanbo/smart/smart_meguji.pdf`.

[17] 農林水産省. **トマト**. トマト栽培および管理に関する基礎資料. 2024. URL: https://www.maff.go.jp/j/seisan/kankyo/hozen_type/h_sehi_kizyun/attach/pdf/aki3-5.pdf.

[18] 農林水産省. **令和 *6* 年度 食料・農業・農村白書 第 *1* 部 食料・農業・農村の動向**. 第 2 章 持続的な発展 第 2 節 担い手の育成・確保. 2024. URL: https://www.maff.go.jp/j/wpaper/w_maff/r5/r5_h/trend/part1/pdf/c3_2_00.pdf.

[19] 農林水産省. **総合防除実践マニュアル**. 2024. URL: https://www.maff.go.jp/j/syouan/syokubo/gaicyu/g_ipm/attach/pdf/index-31.pdf.